

Modelado y Resolución de Problemas mediante Aprendizaje por Refuerzo

Asignatura: Aprendizaje Automático II - Grado en Ciencia de Datos e Inteligencia Artificial

Bloque: Aprendizaje por Refuerzo

1. Objetivo de la Práctica

El objetivo de esta práctica es aplicar los conceptos teóricos y prácticos vistos durante el bloque de Aprendizaje por Refuerzo a un problema del mundo real o un entorno simulado **de vuestra propia elección**.

Deberéis identificar un problema que pueda ser formulado como un Proceso de Decisión de Markov (MDP), formalizar matemáticamente sus componentes, programar el entorno (o adaptarlo a la API de librerías como Gymnasium) y entrenar a un agente utilizando al menos dos algoritmos de Aprendizaje por Refuerzo (por ejemplo, Monte Carlo, SARSA, Q-Learning, o métodos basados en Deep Learning como DQN).

2. Estructura de la Memoria a Entregar

El proyecto deberá acompañarse de una memoria técnica estructurada estrictamente en las siguientes secciones. Esta memoria no debe ser un mero volcado de código, sino un documento analítico que demuestre vuestra comprensión del problema y de los algoritmos empleados.

2.1. Motivación del problema

En esta sección debéis describir de forma general el problema elegido. ¿Por qué es un problema interesante desde la perspectiva de la Ciencia de Datos y la IA? ¿Cuáles son sus aplicaciones en el mundo real? Se valorará la originalidad y la relevancia de la propuesta (ej. optimización de rutas, control de inventario, resolución de un juego, trading financiero, etc.).

2.2. Modelado del problema (Formalización MDP)

Esta es la sección más crítica del diseño. Debéis formalizar vuestro problema como un Proceso de Decisión de Markov. Es obligatorio detallar y justificar explícitamente:

- **Espacio de Estados ($\mathcal{S}$):** ¿Qué variables componen el estado? ¿Es un espacio discreto o continuo? ¿Qué tamaño tiene?
- **Espacio de Acciones ($\mathcal{A}$):** ¿Qué acciones puede tomar el agente en cada estado?
- **Función de Recompensa ($\mathcal{R}$):** ¿Cómo se premia o castiga al agente? (Es crucial justificar la elección para evitar comportamientos no deseados o *reward hacking*).
- **Dinámica de Transición ($\mathcal{P}$):** ¿Es el entorno determinista o estocástico? ¿Es episódico o continuo?
- **Factor de Descuento (γ):** Justificación del valor elegido.

2.3. Breve estado del arte

Una revisión concisa (1-2 páginas) de cómo se ha abordado este problema (o problemas muy similares) anteriormente en la literatura o en la industria. ¿Se suele resolver con heurísticas clásicas, con algoritmos de búsqueda (ej. A*), o con Aprendizaje por Refuerzo? Incluid al menos 3 referencias bibliográficas relevantes.

2.4. Soluciones propuestas y Diseño Experimental

En esta sección detallaréis el enfoque algorítmico utilizado para resolver el problema:

- **Algoritmos elegidos:** Descripción de los algoritmos de RL implementados (ej. contraste entre un método On-Policy

como SARSA y uno Off-Policy como Q-Learning).

- **Hiperparámetros:** Tabla resumen con la tasa de aprendizaje (α), política de exploración (ϵ -greedy, softmax) y su decaimiento, número de episodios, etc.
- **Resultados Experimentales:** Deben incluirse gráficas claras que muestren la evolución de la recompensa acumulada por episodio, la convergencia de la función de valor, o mapas de la política aprendida.

2.5. Conclusiones y Trabajo Futuro

Análisis crítico de los resultados obtenidos. ¿Ha conseguido el agente aprender una política óptima o subóptima? ¿Cuáles han sido las principales limitaciones (tiempo de cómputo, exploración insuficiente, complejidad del estado)? Finalmente, proponed qué mejoras aplicaríais si dispusierais de más tiempo (ej. usar redes neuronales más profundas, refinar la función de recompensa).

3. Rúbrica de Evaluación

La calificación final de la práctica se calculará en base a los siguientes criterios:

Criterio de Evaluación	Ponderación	Descripción
1. Complejidad y Originalidad	20%	Se valorará positivamente la elección de un problema original y desafiante frente a la simple reutilización de entornos pre-resueltos básicos.
2. Rigor en el Modelado (MDP)	20%	La definición matemática de los estados, acciones y recompensas debe ser coherente, sin ambigüedades y adaptada correctamente a las exigencias teóricas del RL.
3. Coherencia Experimental y Soluciones	30%	Implementación correcta de los algoritmos. Uso adecuado de hiperparámetros. Las gráficas y métricas presentadas deben demostrar fehacientemente que el agente ha aprendido.
4. Análisis Crítico (Conclusiones)	15%	Capacidad del alumno para interpretar por qué el agente se comporta como lo hace, detectando fallos en el modelado inicial o en la convergencia.
5. Calidad de la Memoria y Formato	15%	Redacción académica clara, correcta ortografía, código bien comentado y estado del arte bien referenciado.

Nota sobre Plagio e Integridad Académica: El código y la memoria deben ser de autoría propia. Se realizarán controles cruzados sobre las entregas y defensas orales si se considera oportuno.